


DoRA vs LoRA: когда декомпозиция весов помогает?

Владислав Лапин · МФТИ ФПМИ / AI360

Мотивация

Full fine-tuning точен, но обновляет все параметры. LoRA дешевле, однако одна low-rank поправка одновременно меняет норму и направление строк W .
DoRA задаёт $\hat{W} = m \odot V / \|V\|_2$, где $V = W_0 + BA$: BA отвечает за направление, m - за масштаб каждой строки.
Исследовательский вопрос: когда дополнительные magnitude-параметры действительно дают преимущество, а когда LoRA достаточно?



Одинаковый rank r ; у DoRA добавляется d_{out} magnitude-параметров.

Рис. 1. LoRA связывает масштаб и направление; DoRA разделяет их явно.

Гипотезы и метрики

H1 · аддитивный target ($\gamma = 0$): при rank ≥ 4 методы должны совпасть.

H2 · неоднородный row scaling ($\gamma > 0$): разрыв ёмкости LoRA растёт; DoRA сохраняет точность.

H3 · реальные shifts: выигрыш будет умеренным и зависимым от геометрии сдвига.

Метрики: relative Frobenius error; test accuracy; paired DoRA–LoRA с 95% t-CI; число trainable parameters.

Протокол

Capacity test: $W^\star = \text{diag}(1 + \gamma z)(W_0 + \Delta r=4)$; $\gamma = 0 \dots 0.8$, ranks 1/2/4/8, 10 seeds. LoRA - точный SVD oracle.

Real-data test: Digits; MLP $64 \rightarrow 128 \rightarrow 64 \rightarrow 10$; 400 адаптационных примеров; contrast, rotation и mixed; 5 paired seeds.

Без утечки: LR и early stopping выбирались по validation; test применён один раз. Контроли: frozen, magnitude-only, full FT.

Два уровня проверки

Ёмкость: может ли параметризация выразить целевую матрицу без влияния оптимизатора?

Обучение: сохраняется ли эффект при конечных данных, SGD и выборе гиперпараметров?

Фальсифицируемость: $\gamma = 0$, contrast shift и rotation $r=8$ служат отрицательными примерами.

Главный результат

Синтетика, $r=4$, $\gamma=.8$: LoRA oracle error = 0.2923; DoRA $\leq 1.5 \times 10^{-7}$. При $\gamma=0$ обе ошибки ≈ 0 .

Реальные shifts, $r=4$: DoRA–LoRA = +0.33 pp contrast, +0.67 pp rotation, +1.39 pp mixed; CI > 0 для rotation и mixed.

Контрпример: rotation $r=8$ - LoRA 94.61%, DoRA 94.22%.

Универсального превосходства нет.




Рис. 2. Capacity gap и paired test gain; среднее $\pm$ 95% CI, 5 seeds.

Практический вывод

Mixed, $r=4$: Frozen 50.83 · m-only 65.89 · LoRA 73.33 · DoRA 74.72 · Full FT 73.33%.

Mixed, $r=8$: DoRA 77.33% против LoRA 75.44%.

Бюджет $r=4$: DoRA 2,034; LoRA 1,832 (+11%); full FT 17,226 trainable parameters.

Validation-selected mixed: DoRA 76.72 · LoRA 75.28 · full FT 73.33%.

Итог: DoRA оправдана, когда ожидается drift норм строк и особенно важен малый rank. В остальных случаях LoRA остаётся сильным baseline.

Ограничения: малый MLP/dataset, 5 seeds; не измерены transformer-scale качество и throughput.

[1] Liu et al. DoRA: Weight-Decomposed Low-Rank Adaptation. ICML 2024, PMLR 235.

[2] Hu et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022.

[3] scikit-learn Digits; код, seeds, CSV и notebook - GitHub (QR).

