

Research Proposal: обзор DoRA для эффективной адаптации моделей

Владислав Лапин, МФТИ ФПИИ / AI360. Статья: Liu et al., *DoRA: Weight-Decomposed Low-Rank Adaptation*, ICML 2024 Oral.

1. Обзор статьи и контекст. Полное дообучение (full fine-tuning) остается сильным способом адаптировать модель под новую задачу: оно обновляет все веса и обычно дает высокое качество. Проблема не в том, что full fine-tuning “плохой”, а в том, что для LLM/VLM он дорог по памяти, времени и хранению отдельных копий модели. LoRA [1] уменьшает стоимость дообучения: исходная матрица W_0 замораживается, а обучается низкоранговая поправка

$$\widehat{W} = W_0 + \Delta W, \quad \Delta W = \frac{\alpha}{r}BA, \quad A \in \mathbb{R}^{r \times d_{in}}, \quad B \in \mathbb{R}^{d_{out} \times r}.$$

После LoRA появились методы, которые не просто ставят адаптеры одинаково, а пытаются распределять бюджет адаптации более осмысленно: по слоям, модулям или компонентам. Например, AdaLoRA [2] перераспределяет rank по важности. DoRA [3] развивает эту линию иначе: авторы утверждают, что LoRA смешивает изменение направления и масштаба веса, тогда как full fine-tuning меняет эти компоненты по-разному.

2. К чему применяется DoRA и какие результаты дает статья. В версии статьи на arXiv авторы проверяют DoRA на семействе LLaMA, LLaVA и VL-BART: commonsense reasoning, visual instruction tuning, image/video-text understanding. Это показывает область применения метода: DoRA нужен не для игрушечной линейной задачи, а для адаптации больших языковых и vision-language моделей, где полный full fine-tuning часто слишком дорог. В статье сообщается, что DoRA превосходит LoRA в ряде задач: например, дает прирост к LoRA на commonsense reasoning для LLaMA-7B/13B, LLaMA2-7B, LLaMA3-8B, а также на LLaVA и VL-BART.




Рис. 1: Где применяется DoRA и какие приросты над LoRA заявлены авторами статьи. График построен по краткому описанию результатов из статьи; он нужен как контекст, а не как мой эксперимент.

3. Основная математика метода. DoRA параметризует адаптированный вес как нормированное направление с отдельным масштабом:


$$\widehat{W} = m \odot \frac{V}{\|V\|_c}, \quad V = W_0 + \frac{\alpha}{r}BA.$$

Здесь V отвечает за изменение направления, а m - обучаемая magnitude-компонента по выбранной размерности c . Интуитивно LoRA двигает вес только в low-rank подпространстве, а DoRA дополнительно дает модели управлять нормой весов. За счет этого DoRA ближе имитирует поведение full fine-tuning, но сохраняет малое число обучаемых параметров и после слияния с весами не добавляет задержку на инференсе.



Рис. 2: Схема перерисована по идее Figure 1 из DoRA: pretrained weight раскладывается на magnitude и direction, а LoRA применяется к направлению.

4. Минимальный эксперимент и перепроверка результатов. Для проверки центрального механизма я провел контрольный эксперимент. Есть замороженная матрица W_0 и целевая матрица W_* , которая отличается от W_0 и направлением, и нормами. Сравниваются замороженная матрица, LoRA rank 4 и DoRA rank 4. Эксперимент запускался на нескольких seed ($n = 3$), после чего были пересчитаны среднее и стандартное отклонение по test MSE.



Комментарий к графике. Логарифмическая шкала нужна, потому что ошибка DoRA на два-три порядка меньше ошибки LoRA. Это не воспроизводит большие эксперименты статьи на LLaMA/LLaVA, но проверяет геометрию метода: когда целевая матрица отличается от исходной по масштабу и направлению, обычная low-rank поправка оставляет заметную ошибку, а DoRA почти полностью восстанавливает целевую матрицу при близком числе параметров.

5. Что можно улучшить и следующий эксперимент. Слабое место DoRA - дополнительная стоимость на этапе обучения и необходимость выбирать, где обучать magnitude-компоненту. Поэтому естественное развитие - не ставить DoRA одинаково во все модули, а выбирать адаптеры оптимально: по слоям, матрицам и rank. Один возможный вариант - layer-wise DoRA budget allocation: для слоя l выбирать пару (r_l, m_l) по validation loss или gradient norm. Следующий практический эксперимент - проверить LoRA/DoRA через Hugging Face PEFT на DistilBERT/SST-2 при rank 4 и 8 по ассурасу, F1, числу параметров и времени обучения.

Список литературы

- [1] Hu et al. *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR 2022. <https://arxiv.org/abs/2106.09685>
- [2] Zhang et al. *AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning*. ICLR 2023. <https://arxiv.org/abs/2303.10512>
- [3] Liu et al. *DoRA: Weight-Decomposed Low-Rank Adaptation*. ICML 2024 Oral. <https://arxiv.org/abs/2402.09353>
- [4] Hugging Face PEFT documentation, LoRA/DoRA configuration. https://huggingface.co/docs/peft/main/en/package_reference/lora